

Observatoire IA — Talents marocains

Fonctionnement de l'algorithme de collecte et de sélection · Version 1.0

1. Objectif

Constituer automatiquement un annuaire de chercheurs et ingénieurs **marocains** (résidents et diaspora) travaillant en **intelligence artificielle**, en distinguant les profils de référence des profils émergents.

Trois contraintes déterminent toute la conception :

- **Uniquement l'IA**, dans toutes ses branches : machine learning, deep learning, NLP, vision par ordinateur, apprentissage par renforcement.
- **Uniquement des Marocains** — c'est la contrainte la plus difficile : aucune base publique ne stocke la nationalité.
- **Hiérarchiser** les profils par niveau, pour pouvoir n'afficher que l'élite.

2. Vue d'ensemble

- 1 **Découverte** — interrogation d'OpenAlex pour lister les auteurs rattachés à une institution marocaine et actifs sur des sujets IA.
- 2 **Déduplication** — fusion des doublons (même ORCID, même OpenAlex ID, ou score de rapprochement croisé).
- 3 **Filtres qualité** — seuils minimum de publications, h-index, activité récente.
- 4 **Focus IA** — mesure de la part réelle du travail consacrée à l'IA.
- 5 **Origine marocaine** — vérification croisée avec ORCID, puis routage accepté / à vérifier / rejeté.
- 6 **Classement par niveau** — attribution d'un tier sur des seuils absolus.
- 7 **Publication** — chargement dans la base, exposée par l'API FastAPI et affichée par le front React.

3. Étape 1 — Découverte (OpenAlex)

OpenAlex est une base ouverte de publications scientifiques. On y interroge l'index des *auteurs* avec un filtre combiné :

```
affiliations.institution.country_code:MA + topics.id:<77 sujets IA>
```

La liste des sujets IA est résolue dynamiquement depuis le sous-domaine OpenAlex **1702 (Artificial Intelligence)**, complété par **1707 (Computer Vision)**. Deux stratégies sont lancées en parallèle :

Stratégie	Filtre	Population visée
resident	<code>last_known_institutions.country_code:MA</code>	Chercheurs actuellement basés au Maroc
diaspora	<code>affiliations.institution.country_code:MA</code>	Institution marocaine dans l'historique, aujourd'hui à l'étranger

Piège corrigé. Une version antérieure utilisait `/authors?search=machine learning`. Or OpenAlex ne cherche là que dans le *nom* de l'auteur : la requête remontait des entités littéralement nommées « Machine Learning » (séminaires, laboratoires) et zéro chercheur. C'était la cause du pipeline vide.

4. Étape 4 — Mesurer le focus IA

OpenAlex indique, pour chaque auteur, la répartition de ses travaux par sujet. On en déduit la **pureté IA** :

`ai_purity = travaux dans les sous-domaines IA / total des travaux`

Un chercheur NLP est proche de 1.0 ; un cardiologue ayant publié un seul article avec un réseau de neurones est à 0.03. Mais la part seule ne suffit pas :

Le piège de l'IA interdisciplinaire. Un chercheur majeur en *federated learning* dont les articles sont classés en « communications sans fil » tombe à 0.15 de pureté, tout en ayant plus de cent travaux IA. Un filtre par part seule l'éliminait — alors qu'une grande partie de la recherche IA marocaine se situe précisément à ces intersections (sécurité, réseaux, imagerie médicale).

Le filtre retenu combine donc part **et** volume, avec un plancher de pureté :

`ai_purity ≥ 0.25 OU (ai_works ≥ 20 ET ai_purity ≥ 0.10)`

Le spécialiste au dossier court mais 100 % IA passe par la première branche ; le chercheur interdisciplinaire prolifique passe par la seconde. Le cardiologue échoue aux deux.

5. Étape 5 — Prouver l'origine marocaine

C'est le cœur du problème. OpenAlex ne stocke pas la nationalité, et rattache une institution à un auteur dès **un seul article co-signé**. Un chercheur étranger ayant collaboré une fois avec un laboratoire marocain apparaît donc comme « affilié Maroc ».

Constat contre-intuitif. Relever le seuil d'excellence *aggrave* le problème. En appliquant `h-index ≥ 40` sans contrôle d'origine, on obtenait 11 profils dont **2 seulement étaient marocains** : les chercheurs très cités co-signent beaucoup, donc ils dominent le haut du classement. D'où la règle : **filtrer l'origine d'abord, l'excellence ensuite.**

Le signal décisif : ORCID

ORCID est un identifiant chercheur où chacun déclare lui-même ses diplômes et ses postes, avec le pays de chaque institution. C'est la meilleure preuve d'identité disponible. Sur le jeu de test, il a correctement

écarté 7 profils étrangers sur 7 — dont un Tunisien, un Espagnol et trois Français que l'affiliation OpenAlex laissait passer.

Règle de routage

Preuve ORCID	Signal OpenAlex	Verdict
pays contient MA	—	Accepté
pays étrangers uniquement	basé au Maroc, ou ≥ 2 institutions marocaines	À vérifier
pays étrangers uniquement	une seule institution marocaine	Rejeté
aucune donnée ORCID	basé au Maroc + affiliation durable	Accepté
aucune donnée ORCID	sinon	À vérifier

Pourquoi « à vérifier » et pas « rejeté ». ORCID est très précis mais incomplet : un membre de la diaspora parti du Maroc avant l'existence d'ORCID n'y déclare que des pays étrangers. Le nombre d'**institutions marocaines distinctes** les départage — une carrière marocaine en traverse plusieurs, un collaborateur étranger n'est rattaché qu'au seul labo partenaire. En cas de doute, le profil part en relecture humaine plutôt qu'à la poubelle.

6. Étape 6 — Le classement par niveau

Piège corrigé. Le score était une normalisation min-max à l'intérieur du lot téléchargé. Un seul profil hors-norme écrasait tous les autres, et le niveau d'une même personne changeait d'un run à l'autre. Résultat : le seuil « Elite » était mathématiquement inatteignable et 100 % des profils ressortaient « Emergent ».

Les niveaux reposent désormais sur des **seuils absolus**, stables et comparables dans le temps :

Niveau	Condition
Elite	$h\text{-index} \geq 40$ ET focus IA fort (pureté ≥ 0.5 ou ≥ 50 travaux IA) ET publication dans les 5 ans
Confirmé	$h\text{-index} \geq 25$ ET focus IA
Emergent	$h\text{-index} \geq 10$ ET focus IA
Exclu	en dessous — retiré de la publication

Le score reste utilisé, mais uniquement pour **trier** à l'intérieur d'un niveau.

7. Résultats et sorties

1092 PROFILS SCANNÉS	137 ACCEPTÉS	1 ELITE	2 CONFIRMÉ	134 EMERGENT	57 À VÉRIFIER
-----------------------------------	------------------------	-------------------	----------------------	------------------------	-------------------------

Fichier	Contenu
experts.json	Profils acceptés — origine marocaine confirmée. C'est ce qui alimente l'API.
review_queue.csv	Profils à vérifier à la main . À lire avant toute publication.
rejected.csv	Profils écartés, avec le filtre responsable (<code>excluded_by</code>). Premier endroit à regarder si le pipeline ne sort rien.

8. Limites connues

- **Le vivier d'élite est très restreint.** Au niveau `h-index ≥ 40` et réellement IA, on compte une poignée de personnes. Ce n'est pas un défaut de réglage : la population est objectivement petite.
- **Scanner plus profond n'apporte pas d'élites.** La requête trie par nombre de citations décroissant : les plus cités sont déjà sur la première page. Multiplier le volume par 5 n'a ajouté aucun profil Elite ou Confirmé, seulement des profils émergents.
- **Faux négatifs ORCID.** Des chercheurs marocains reconnus n'ont aucune trace marocaine dans ORCID. Ils partent en relecture — d'où l'importance de traiter `review_queue.csv`.
- **Erreurs de fusion OpenAlex.** La base attribue parfois à un auteur des affiliations qui ne sont pas les siennes. Les filtres de profondeur limitent l'impact sans l'éliminer.
- **GitHub est marginal sans token.** L'API anonyme est limitée à 60 requêtes/heure. Avec un `GITHUB_TOKEN`, la limite passe à 5000.

9. Relancer et régler

Depuis la racine du dépôt :

```
python -m etl.run_etl --no-db --json-out etl/output/experts.json --rejections-csv
etl/output/rejected.csv --review-csv etl/output/review_queue.csv
```

Puis pour alimenter l'API : `cd backend && python seed.py --json-path ../etl/output/experts.json`

Les réglages se font dans `etl/.env` — aucun code à modifier :

Variable	Effet
MAX_PAGES	Volume scanné (50 profils par page et par stratégie)
MIN_AI_PURITY / MIN_AI_WORKS	Sévérité du focus IA
MIN_MOROCCAN_AFFILIATION_INSTITUTIONS	Exigence de preuve d'origine
TIER_ELITE_MIN_H_INDEX	Barre du niveau Elite
GITHUB_TOKEN	Débloque réellement la source GitHub