

Observatoire IA — Talents marocains

Fonctionnement de l'algorithme de collecte et de sélection · Version 1.0

1. Objectif

Constituer automatiquement un annuaire de chercheurs et ingénieurs marocains **résidant hors du Maroc** — la diaspora — travaillant en **intelligence artificielle**, en distinguant les profils de référence des profils émergents.

Trois contraintes déterminent toute la conception :

- **Uniquement l'IA**, dans toutes ses branches : machine learning, deep learning, NLP, vision par ordinateur, apprentissage par renforcement.
- **Uniquement des Marocains, et uniquement hors du Maroc** — c'est la contrainte la plus difficile : aucune base publique ne stocke la nationalité, et une fois à l'étranger, un Marocain et un étranger sont indiscernables par leur institution actuelle.
- **Hiérarchiser** les profils par niveau, pour pouvoir n'afficher que l'élite.

Périmètre. Les chercheurs actuellement en poste au Maroc sont *volontairement exclus*. Ce n'est pas un défaut de collecte : l'annuaire vise la diaspora.

2. Vue d'ensemble

❶ **Découverte** — interrogation d'OpenAlex pour lister les auteurs rattachés à une institution marocaine et actifs sur des sujets IA.

❷ **Déduplication** — fusion des doublons (même ORCID, même OpenAlex ID, ou score de rapprochement croisé).

❸ **Filtres qualité** — seuils minimum de publications, h-index, activité récente.

❹ **Focus IA** — mesure de la part réelle du travail consacrée à l'IA.

❺ **Origine marocaine** — vérification croisée avec ORCID, puis routage accepté / à vérifier / rejeté.

❻ **Classement par niveau** — attribution d'un tier sur des seuils absolus.

❼ **Publication** — chargement dans la base, exposée par l'API FastAPI et affichée par le front React.

3. Étape 1 — Découverte (OpenAlex)

OpenAlex est une base ouverte de publications scientifiques. On y interroge l'index des *auteurs* avec un filtre combiné :

```
affiliations.institution.country_code:MA + last_known_institutions.country_code:!MA +  
topics.id:<77 sujets IA>
```

Soit : une institution marocaine dans l'historique, une institution actuelle **hors** du Maroc (la clause négative), et une activité sur des sujets IA. La liste des sujets est résolue dynamiquement depuis le sous-domaine OpenAlex **1702 (Artificial Intelligence)**, complété par **1707 (Computer Vision)**.

Attention. `last_known_institutions` est une *liste*. Un chercheur rattaché à la fois à une institution marocaine et à une institution étrangère est traité comme résident au Maroc, donc exclu. C'est le comportement voulu, mais il écarte aussi les doubles affiliations réelles.

Piège corrigé. Une version antérieure utilisait `/authors?search=machine learning`. Or OpenAlex ne cherche là que dans le *nom* de l'auteur : la requête remontait des entités littéralement nommées « Machine Learning » (séminaires, laboratoires) et zéro chercheur. C'était la cause du pipeline vide.

4. Étape 4 — Mesurer le focus IA

OpenAlex indique, pour chaque auteur, la répartition de ses travaux par sujet. On en déduit la **pureté IA** :

```
ai_purity = travaux dans les sous-domaines IA / total des travaux
```

Un chercheur NLP est proche de 1.0 ; un cardiologue ayant publié un seul article avec un réseau de neurones est à 0.03. Mais la part seule ne suffit pas :

Le piège de l'IA interdisciplinaire. Un chercheur majeur en *federated learning* dont les articles sont classés en « communications sans fil » tombe à 0.15 de pureté, tout en ayant plus de cent travaux IA. Un filtre par part seule l'éliminait — alors qu'une grande partie de la recherche IA marocaine se situe précisément à ces intersections (sécurité, réseaux, imagerie médicale).

Le filtre retenu combine donc part **et** volume, avec un plancher de pureté :

```
ai_purity ≥ 0.25 OU (ai_works ≥ 20 ET ai_purity ≥ 0.10)
```

Le spécialiste au dossier court mais 100 % IA passe par la première branche ; le chercheur interdisciplinaire prolifique passe par la seconde. Le cardiologue échoue aux deux.

5. Étape 5 — Prouver l'origine marocaine

C'est le cœur du problème. OpenAlex ne stocke pas la nationalité, et rattache une institution à un auteur dès **un seul article co-signé**. Un chercheur étranger ayant collaboré une fois avec un laboratoire marocain apparaît donc comme « affilié Maroc ».

Constat contre-intuitif. Relever le seuil d'excellence *aggrave* le problème. En appliquant $h\text{-index} \geq 40$ sans contrôle d'origine, on obtenait 11 profils dont **2 seulement étaient marocains** : les chercheurs très cités co-signent beaucoup, donc ils dominent le haut du classement. D'où la règle : **filtrer l'origine d'abord, l'excellence ensuite.**

Le piège qui a coûté le plus cher. Une version antérieure rejetait un profil dont ORCID ne mentionnait que des pays étrangers. C'est exactement la signature d'un membre de la diaspora — la population visée. La règle éliminait donc en priorité les profils recherchés, dont Mehdi Bennis ($h\text{-index}$ 86). L'ordre est important : d'abord vérifier que la personne est *hors du Maroc*, ensuite qu'elle est marocaine d'origine.

Une fois à l'étranger, l'institution actuelle ne dit plus rien : un Marocain à Oulu et un Finlandais à Oulu sont identiques dans OpenAlex. Il faut donc remonter à l'origine.

Le signal décisif : où la carrière a commencé

On compare l'année de la première publication à celle de la première affiliation marocaine, rapportée à la durée totale de la carrière :

`moroccan_career_fraction = (1re affiliation MA – 1re publication) / durée de carrière`

Chercheur	1re publi.	1re affil. MA	Fraction	Réalité
Mehdi Bennis	1989	1989	0.00	marocain
Rachid Alami	1980	1980	0.00	marocain
Jean-Claude Martin	1966	2000	0.57	étranger
Xin-She Yang	1986	2013	0.68	étranger
Ignacio Rojas	1895	2016	0.93	étranger

Un émigré marocain **démarre** sa carrière au Maroc : fraction proche de 0. Un collaborateur étranger acquiert une affiliation marocaine des décennies après ses débuts. La mesure est une fraction et non un écart en années, pour valoir aussi bien sur une carrière de 40 ans que de 10.

Règle de routage

Condition	Verdict
en poste au Maroc	Rejeté (hors périmètre)
ORCID déclare une formation ou un poste au Maroc	Accepté
carrière démarrée au Maroc et ≥ 2 institutions marocaines	Accepté
carrière démarrée au Maroc, une seule institution	À vérifier
pas de chronologie exploitable, mais ≥ 2 institutions marocaines	À vérifier
sinon	Rejeté

Pourquoi la chronologie décide, et pas le nombre d'institutions. Un chercheur étranger accumule deux laboratoires partenaires marocains aussi facilement qu'un seul : compter les institutions laissait passer des collaborateurs tardifs (fraction 0.57, 0.66, 0.93). Le nombre d'institutions ne sert donc qu'à départager « accepté » de « à vérifier », une fois le signal de chronologie acquis. ORCID reste la preuve la plus forte quand elle existe, mais sa couverture est faible : Mehdi Bennis n'y déclare que la Suisse, la Finlande et la France.

6. Étape 6 — Le classement par niveau

Piège corrigé. Le score était une normalisation min-max à l'intérieur du lot téléchargé. Un seul profil hors-norme écrasait tous les autres, et le niveau d'une même personne changeait d'un run à l'autre. Résultat : le seuil « Elite » était mathématiquement inatteignable et 100 % des profils ressortaient « Emergent ».

Les niveaux reposent désormais sur des **seuils absolus**, stables et comparables dans le temps :

Niveau	Condition
Elite	$h\text{-index} \geq 40$ ET focus IA fort (pureté ≥ 0.5 ou ≥ 50 travaux IA) ET publication dans les 5 ans
Confirmé	$h\text{-index} \geq 25$ ET focus IA
Emergent	$h\text{-index} \geq 10$ ET focus IA
Exclu	en dessous — retiré de la publication

Le score reste utilisé, mais uniquement pour **trier** à l'intérieur d'un niveau.

7. Résultats et sorties

1930

CANDIDATS ORCID

24

ÉTABLISSEMENTS INTERROGÉS

~0,01 \$

COÛT D'UN RUN

Le run complet reste à mesurer. Le pipeline a été réorienté vers la diaspora et chaque brique a été validée séparément, mais aucun lancement complet n'a encore abouti : le budget quotidien OpenAlex a été épuisé avant. Les chiffres d'un précédent run (137 profils acceptés) portaient sur la population *résident au Maroc* — l'objectif inverse — et ne sont donc pas reportés ici. Le décompte réel sera connu au premier run complet.

Fichier	Contenu
experts.json	Profils acceptés — origine marocaine confirmée. C'est ce qui alimente l'API.
review_queue.csv	Profils à vérifier à la main . À lire avant toute publication.
rejected.csv	Profils écartés, avec le filtre responsable (<code>excluded_by</code>). Premier endroit à regarder si le pipeline ne sort rien.

8. Limites connues

- **Le vivier d'élite est très restreint.** Au niveau `h-index ≥ 40` et réellement IA, on compte une poignée de personnes. Ce n'est pas un défaut de réglage : la population est objectivement petite.
- **Scanner plus profond n'apporte pas d'élites.** La requête trie par nombre de citations décroissant : les plus cités sont déjà sur la première page. Multiplier le volume par 5 n'a ajouté aucun profil Elite ou Confirmé, seulement des profils émergents.
- **Faux négatifs ORCID.** Des chercheurs marocains reconnus n'ont aucune trace marocaine dans ORCID. Ils partent en relecture — d'où l'importance de traiter `review_queue.csv`.
- **Erreurs d'institution OpenAlex.** Cas vérifié : Olivier Colliot, chercheur CNRS à Paris, est accepté à tort. OpenAlex rattache son passage à *Télécom Paris* (2002-2004) à une « École Supérieure des Télécommunications » étiquetée marocaine ; sa carrière semble alors commencer au Maroc.
- **Homonymes fusionnés.** La fiche « Rachid Alami » mélange un roboticien du CNRS à Toulouse et un chercheur marocain en énergie nucléaire. Elle passe tous les filtres, mais les deux signaux appartiennent à deux personnes.
- **Conséquence pratique :** relire les profils un par un avant publication, en particulier ceux dont la preuve marocaine tient à une seule institution sur peu d'années.
- **GitHub est marginal sans token.** L'API anonyme est limitée à 60 requêtes/heure. Avec un `GITHUB_TOKEN`, la limite passe à 5000.

9. Relancer et régler

Depuis la racine du dépôt :

```
python -m etl.run_etl --no-db --json-out etl/output/experts.json --rejections-csv etl/output/rejected.csv --review-csv etl/output/review_queue.csv
```

Puis pour alimenter l'API : `cd backend && python seed.py --json-path ../etl/output/experts.json`

Les réglages se font dans `etl/.env` — aucun code à modifier :

Variable	Effet
<code>MAX_PAGES</code>	Volume scanné (50 profils par page et par stratégie)
<code>MIN_AI_PURITY</code> / <code>MIN_AI_WORKS</code>	Sévérité du focus IA
<code>MIN_MOROCCAN_AFFILIATION_INSTITUTIONS</code>	Exigence de preuve d'origine
<code>TIER_ELITE_MIN_H_INDEX</code>	Barre du niveau Elite
<code>GITHUB_TOKEN</code>	Débloque réellement la source GitHub